

1. Introduction

L'entreprise InduTechData fait face à une augmentation significative de ses données IoT (+50 Go/mois). L'objectif est de moderniser l'infrastructure tout en conservant la compatibilité avec le SI existant on-premise. L'architecture hybride proposée combine des composants locaux (SQL Server, SAN, Active Directory) avec des services AWS afin d'assurer scalabilité, performance et sécurité.

2. Justification des composants

2.1 Redpanda (Streaming IoT)

Redpanda est utilisé pour la gestion des flux temps réel issus des capteurs IoT. Il permet un traitement à faible latence et une forte scalabilité.

Sa compatibilité avec Kafka facilite son intégration dans un environnement hybride et existant.

2.2 Amazon S3 (Data Lake)

S3 est utilisé comme stockage principal des données brutes (zone Bronze) : flux IoT mais aussi potentiellement d'autres fichiers source (JSON, CSV, logs bruts). C'est aussi le stockage des données nettoyées et enrichies (zone Silver).

Il offre une scalabilité quasi illimitée, un coût optimisé et une intégration native avec les services analytiques AWS. Il constitue le socle de l'architecture médaillon.

2.3 Amazon Redshift (Data Warehouse)

Redshift permet d'effectuer des analyses avancées sur les données transformées (zone Gold). Il est optimisé pour les requêtes analytiques.

Redshift peut également interroger directement S3 via Spectrum pour certains cas d'usage spécifiques, mais cela ne remplace pas la modélisation en couche Gold.

2.4 AWS DataSync et AWS DMS

AWS DataSync est utilisé pour transférer les fichiers du SAN vers S3.

AWS DMS permet la migration et la synchronisation des bases SQL Server vers le cloud.

Ces outils assurent une transition fluide entre on-premise et cloud.

2.5 AWS Direct Connect / VPN

Assure une connectivité sécurisée et stable entre le datacenter et AWS. Permet de réduire la latence et d'améliorer la sécurité des échanges.

2.6 AWS Directory Service

Permet la synchronisation avec Active Directory afin de conserver une gestion centralisée des identités.

2.7 CloudWatch

Assure le monitoring, la supervision et le suivi des coûts de l'infrastructure.

3. Compatibilité avec le SI existant

3.1 Sécurité

Les flux sont chiffrés via TLS. AWS Direct Connect limite l'exposition au réseau public.

La gestion des identités reste centralisée via Active Directory.

3.2 Interopérabilité

L'architecture permet une intégration fluide entre systèmes legacy (SQL Server, SAN) et services cloud grâce à DMS, DataSync et Redpanda.

3.3 Scalabilité

S3 et Redshift permettent d'absorber la croissance des données IoT sans refonte majeure.

4. Coûts

L'utilisation de services managés permet un paiement à l'usage et une optimisation des coûts via CloudWatch et AWS Budgets.

4.1 Surveiller les coûts

Avec **AWS CloudWatch** des métriques permettent de détecter le sur/sous-dimensionnement, par exemple :

- EC2 (Redpanda) :
 - CPUUtilization
 - NetworkIn / NetworkOut
- S3 :
 - BucketSizeBytes
 - NumberOfObjects
- Redshift :
 - QueryDuration
 - CPU / Concurrency

Des alertes peuvent être mises sur des seuils (min / max) ou des vitesses d'augmentation.

Des logs (Redpanda, DMS, DataSync) permettent de vérifier la pertinence des flux.

Avec **AWS Budgets** il est possible d'obtenir de la visibilité sur les coûts et de prévenir les dérives financières, en configurant :

- Le budget mensuel global
- Le budget par service
- Les alertes automatiques (déclenchement avant dépassement)

4.2 Estimation des coûts

L'estimation des coûts est basée sur un environnement non production (POC) afin de fournir un ordre de grandeur. En environnement de production, les coûts seraient significativement plus élevés en raison des exigences de haute disponibilité, de sécurité et de performance.

Estimation pour 50 Go / mois IoT et région EU :

- EC2 (Redpanda streaming), instance t3.large : ~ 70 €/mois
- S3 (Data Lake Bronze + Silver), 0.023 €/Go : ~ 2 €/mois
- Redshift (Data Warehouse Gold), dc2.large : 150-250 €/mois
- DataSync, 0.0125 \$/Go transféré : ~ 2 €/mois
- DMS, Instance légère : 30-50 €/mois
- VPN (alternative low cost à Direct Connect) : ~30 €/mois
- CloudWatch (logs + métriques) : 5-15 €/mois
- AWS Directory Service : 30-50 €/mois

L'architecture présente un coût mensuel estimé entre 400 et 450 €, dominé par Redshift, tandis que S3 permet un stockage scalable et économique. Une attention particulière doit être portée aux transferts de données et à l'optimisation des ressources afin d'éviter toute dérive des coûts.

5. Conclusion

Avantages :

- Scalabilité
- Haute performance
- Intégration hybride
- Sécurité renforcée

Limitations :

- Complexité technique
- Dépendance au cloud
- Coûts variables

L'architecture hybride proposée répond aux besoins d'InduTechData en combinant robustesse, évolutivité et performance.

Elle constitue une base solide pour une modernisation progressive du SI à partir d'une première implémentation ayant un impact minimal sur l'existant (réduction des risques et des coûts de développement initiaux).